




1. Sources de données

- Ici, les **données structurer et non structurer** proviennent de différentes sources.
- Exemple :
 - **Bases relationnelles** (Oracle, Postgrace).
 - **Image depuis des fichiers multimédias**
 - **Données textuelles depuis des fichier plat (CSV)**

2. Intégration / Transformation (ETL)

- Les données brutes sont **extraites (Extract)** des sources.
- Elles sont **transformées (Transform)** :
 - Nettoyage du texte.
 - Tokenisation.
 - Vectorisation via un modèle NLP (`sentence-transformers`, BioBERT, etc.).
 - Normalisation des vecteurs si nécessaire.
- Elles sont **chargées (Load)** dans Oracle
Pipeline Python + Oracle.

3. Exploitation (Analyse / ML)

Une fois les données vectorisées et stockées :

- **Machine Learning**
 - Clustering de documents (K-means, DBSCAN).
 - Recherche sémantique vectorielle (via Oracle vector search).

- Classification automatique de textes (NLP).

RÉCAPITULATIF

- Phase **ELT** : extraction des données sources, vectorisation avec Python.
- Phase **Data Lake** : stockage des vecteurs dans Oracle + HDFS/NoSQL.
- Phase **Exploitation** : requêtes SQL + machine learning sur les vecteurs.