




1. Sources de données (ERP, CRM, Fichiers plats, SGBD, NoSQL, HDFS)

- Ici, les **données textuelles, images, vidéos** proviennent de différentes sources.
- Exemple :
 - **Textes ou articles** depuis un ERP/CRM.
 - **Logs ou documents PDF** stockés dans HDFS.
 - **Bases relationnelles** (Oracle, MySQL).
 - **Image ou vidéos** depuis des base de Données NoSQL (MongoDB).

2. Intégration / Transformation (ELT & Oracle Big Data SQL)

- Les données brutes sont **extraites (Extract)** des sources.
- Elles sont **transformées (Transform)** :
 - Nettoyage du texte.
 - Tokenisation.
 - Vectorisation via un modèle NLP (*sentence-transformers*, BioBERT, etc.).
 - Normalisation des vecteurs si nécessaire.
- Elles sont **chargées (Load)** dans Oracle **pipeline Python + Oracle**.

Data Lake (Physique ou Virtuel)

- **Data Lake Physique** : stockage des données brutes (sur HDFS).
- **Data Lake Virtuel** : grâce à **Oracle Big Data SQL**, on peut interroger à la fois :
 - Les vecteurs dans Oracle.
 - Les fichiers dans HDFS.
 - Les données NoSQL.
 - Les bases relationnelles.

4. Exploitation (Analyse / ML / BI)

Une fois les données vectorisées et stockées :

- **Analyse OLAP / Reporting**
 - Mesurer la similarité entre documents.
- **Machine Learning / Deep Learning**
 - Clustering de documents (K-means, DBSCAN).
 - Recherche sémantique vectorielle (via FAISS + Oracle).
 - Classification automatique de textes.
- **BI et Data Mining**
 - Détection de tendances.
 - Analyse prédictive avec Oracle Machine Learning (OML)

RÉCAPITULATIF

- Phase **ELT** : extraction des données sources, vectorisation avec Python.
- Phase **Data Lake** : stockage des vecteurs dans Oracle + HDFS/NoSQL.
- Phase **Exploitation** : requêtes SQL + machine learning sur les vecteurs.